

Dealing with imbalanced classification

Juan García Santos

Universidad Politécnica de Madrid, Spain

Noviembre, 2023

Abstract

El gran número de técnicas enfocadas a lidiar con tareas de clasificación empleando conjuntos de datos desbalanceados muestra la relevancia del área. En la presente revisión, se aborda el estado del arte en estrategias y técnicas para enfrentar el desafío que supone emplear, con éxito, estos conjuntos desbalanceados en tareas de clasificación, tanto binaria como multiclase. Enfocándose en métodos tanto a nivel de datos como a nivel algorítmico, aquí se desarrolla una taxonomía propia, con profundización en el submuestreo y sobremuestreo de los datos, los enfoques híbridos, el ajuste de sensibilidad a costes, la selección adecuada de modelos y el uso de métricas de evaluación apropiadas. Adicionalmente, se plantean unas conclusiones y posibles líneas futuras relativas a las tecnologías mas "de moda", como pudieran ser las redes neuronales.

1 Introducción

La clasificación empleando datos desbalanceados es un problema caracterizado por el hecho de que las clases en el conjunto de datos no están representadas de manera equitativa. Este desequilibrio puede generar sesgos significativos en los modelos empleados, afectando a su rendimiento, especialmente a la hora de clasificar los ejemplos pertenecientes a la clase minoritaria. El objetivo puede describirse como "encontrar un clasificador que proporcione una alta precisión para la clase minoritaria, sin poner en grave peligro la precisión de la clase mayoritaria" (He and Garcia, 2009).

Si no se indica lo contrario, las aproximaciones planteadas a continuación están orientadas a la clasificación binaria y, de forma implícita, a la clasificación multiclase a través de esquemas de descomposición de clases (Krawczyk et al., 2015). Tal y como exponen Zhou et al. (2008), "hay dos formas de diseñar un clasificador multiclase, una es desarrollar un algoritmo multiclase; la otra, descomponer el problema multiclase en múltiples problemas binarios". En la literatura relativa a la clasificación desbalanceada, la aproximación más clásica y frecuente a la hora de lidiar con un problema multiclase consiste en transformarlo en subproblemas que puedan ser abordados con técnicas orientadas a tareas de clasificación binaria (Allwein et al., 2000; Hastie and Tibshirani, 1997; Wu et al., 2003). Los dos esquemas más empleados en la descomposición de clases son el "uno contra todos" y el "uno contra uno".

El primero, consiste en entrenar N clasificadores binarios diferentes, donde N es el número de clases del conjunto de datos, cada uno entrenado para distinguir como positivos los ejemplos de una sola clase y como negativos los ejemplos de todas las clases restantes. Cuando se desea clasificar un nuevo ejemplo, se ejecutan los N clasificadores y se elige el clasificador con el mayor valor de clasificación positiva en su salida (Rifkin and Klautau, 2004). En el segundo, cada modelo clasifica una instancia entre dos únicas clases, obteniendo así $\frac{N \times (N-1)}{2}$ clasificadores.

Los principales inconvenientes de estas aproximaciones son, tanto el coste computacional añadido al pasar de resolver un solo problema multiclase a varios problemas binarios, como la pérdida de información y sobregeneralización que produce su uso, tal y como se menciona en Wang and Yao (2012). Por esto, no solo existe una necesidad de proponer técnicas nuevas, específicas para los problemas multiclase (Esteves, 2020), sino también buscar modificaciones en las técnicas ya existentes en el ámbito binario para proponer extensiones apropiadas, orientándolas adicionalmente al paradigma de la clasificación multiclase.

2 Estado del arte

A la hora de categorizar las técnicas y estrategias empleadas para lidiar con el desbalanceo de los datos, resulta difícil encontrar una taxonomía completamente consensuada. Basándose en revisiones literarias previas como

López et al. (2013); Galar et al. (2011); Beyan and Fisher (2015); Branco and Torgo (2016); Haixiang et al. (2017); Esteves (2020) se plantean dos aproximaciones generales diferentes: una que, mediante la modificación del conjunto de datos, reduzca el desbalanceo de los mismos; y otra orientada al uso de modelos y técnicas capaces de aumentar la robustez del proceso de clasificación frente al desbalanceo, sin la necesidad a priori de modificar el conjunto original. A su vez, dentro de cada sección general se ha englobado de forma conveniente todos aquellos apartados relevantes para autores previos que se han considerado insuficientes como para plantear otra sección general adicional.

2.1 Técnicas a nivel de datos

Esta forma de abordar el problema de la clasificación desbalanceada se centra en técnicas de preprocesamiento de los datos; estas pretenden reducir el impacto del desbalanceo mediante la manipulación de los datos previa a su uso en el proceso de clasificación.

2.1.1 Sobremuestreo de la clase minoritaria

Con los siguientes métodos se pretende crear un superconjunto del conjunto de datos original mediante la creación de instancias nuevas, ya sea replicando algunas existentes o generándolas completamente desde cero. El mayor inconveniente de esta aproximación es que puede fomentar el sobreajuste del modelo de clasificación empleado.

ROS: La estrategia "random over sampler" (Chawla et al., 2002) replica de forma aleatoria instancias de la clase minoritaria. Es muy simple de implementar y usar pero, dado que no genera información nueva, incrementa la probabilidad de que el modelo se sobreajuste.

SMOTE y sus variantes: El algoritmo "Synthetic minority over-sampling technique" planteado inicialmente por Chawla et al. (2002) es un método de generación de muestras sintéticas basado en un parámetro de distancia k . Para generarlas, primero se seleccionan los k vecinos más cercanos de una muestra de la clase minoritaria; segundo, por cada vecino, se obtiene una nueva muestra sintética en base a la siguiente expresión:

$$x_{new} = x + \lambda \times (x_i - x)$$

Con ella, se calcula la diferencia entre los vectores que representan a ambas muestras (siendo x_i el vector de la muestra vecina i -ésima seleccionada y x la muestra de la clase minoritaria original) y se multiplica por un valor aleatorio λ entre 0 y 1. El vector obtenido se suma a la muestra original para así obtener una muestra sintética que se encuentre en un punto aleatorio del segmento que relaciona a la muestra original con el vecino seleccionado. SMOTE es fácilmente aplicable a escenarios multiclase simplemente repitiendo el proceso con todas las clases minoritarias, pero a cambio aumenta el solape entre clases, lo que puede dificultar la tarea de clasificación enormemente. Este algoritmo es extremadamente popular por su facilidad de comprensión, implementación y gran utilidad. Prueba de ello, es el gran número de variantes existentes (Kovács, 2019). A continuación se comentan algunas de las variantes más relevantes y sus diferencias respecto al algoritmo original:

Borderline-SMOTE 1 y 2 Han et al. (2005) propone esta variante que se centra en las instancias minoritarias cercanas a la frontera de decisión con la clase mayoritaria. En lugar de sobremuestrear aleatoriamente todas las instancias de la clase minoritaria, identifica aquellas que están en peligro, es decir, cerca de la frontera de decisión, y genera ejemplos sintéticos, exclusivamente a partir de vecinos de la misma clase si se trata de la versión 2, o también vecinos de otras clases si se trata de la versión 1. Esto ayuda a fortalecer las regiones de frontera, donde es más probable que ocurran errores de clasificación debido al solapamiento entre clases.

ADASYN ADASYN (He et al., 2008) se enfoca en generar más ejemplos sintéticos para aquellas instancias minoritarias que son más difíciles de aprender. El número de ejemplos sintéticos que se generan para una instancia de la clase minoritaria depende del grado de dificultad de clasificación (medido por el número de vecinos de la clase mayoritaria cercanos). Así, las instancias de la clase minoritaria rodeadas por muchas instancias mayoritarias se usaran más para generar muestras sintéticas.

Safe Level SMOTE Esta versión propuesta por Bunkhumpornpat et al. (2009), se centra en la "seguridad" de los ejemplos sintéticos generados, intentando evitar el sobreajuste. Introduce un concepto de "nivel de seguridad" para cada instancia minoritaria, basado en el número de vecinos minoritarios cercanos. Los ejemplos sintéticos se generan preferentemente en regiones donde hay un alto nivel de seguridad, reduciendo así el riesgo de generar ejemplos sintéticos ruidosos o anómalos.

MDO El método Mahalanobis Distance-based Over-sampling (Abdi and Hashemi, 2015) utiliza la distancia de Mahalanobis para medir la similitud entre las muestras. A diferencia de la distancia euclidiana, la distancia de Mahalanobis tiene en cuenta la correlación entre las características y es más efectiva para identificar similitudes en espacios de características correlacionados y de alta dimensionalidad.

En el proceso de MDO, cada muestra de la clase minoritaria recibe un peso de selección basado en el número de sus vecinos más cercanos que tienen la misma etiqueta de clase. MDO selecciona una muestra aleatoria de la clase minoritaria según la distribución de peso y genera una nueva muestra sintética usando una generalización de la ecuación de la elipse:

$$\frac{(x_1^2)}{a \cdot V_1} + \frac{(x_2^2)}{a \cdot V_2} + \dots + \frac{(x_d^2)}{a \cdot V_d} = 1$$

donde x_i son las coordenadas de la muestra en el espacio de características, V_i son las varianzas correspondientes de cada dimensión, y a es un parámetro constante. Esta fórmula define una elipse en el espacio de características, con centro en la solución media de la clase y que pasa por el punto de muestra de la clase minoritaria considerado. Se utiliza para guiar la generación de nuevas muestras sintéticas a partir de puntos a lo largo de su contorno.

Las muestras sintéticas generadas en el espacio transformado son luego convertidas de nuevo al espacio original y se les suma la media de la clase para obtener las nuevas instancias sintéticas. Este método permite que el sobremuestreo se centre en áreas del espacio de características donde la clase minoritaria está subrepresentada, mejorando así la capacidad del modelo para reconocer y clasificar correctamente estas muestras.

RBO y MC-RBO Radial Based oversampling es un método propuesto por Koziarski et al. (2019) que se desarrolló para abordar las limitaciones de los métodos de sobremuestreo basados en vecindad, como SMOTE, a la hora de lidiar con conjuntos de datos dispersos y de poco tamaño en la clase minoritaria. Este algoritmo emplea funciones de base radial (RBF) para estimar el potencial en cada punto del espacio de características, asignando un valor real que refleja la preferencia para que dicho punto pertenezca a la clase minoritaria o mayoritaria. Cada objeto en el conjunto de datos tiene asignada una función RBF gaussiana, cuya polaridad depende de la clase del objeto. La suma de estas funciones RBF determina el potencial en cualquier punto del espacio. El proceso de sobremuestreo en RBO se realiza mediante un algoritmo de optimización iterativo. Existen diversos criterios de optimización, pero se cree que el mejor consiste en minimizar el valor absoluto del potencial, indicando áreas de alta incertidumbre cercanas al límite de decisión. Esto conduce a la generación de objetos sintéticos de la clase minoritaria en regiones donde se equilibra mejor la distribución de clases a la vez que se minimiza la superposición con la clase mayoritaria.

Posteriormente, fue propuesta una versión capaz de atacar problemas multiclase de forma directa (Krawczyk et al., 2019). Para ello, las clases se ordenan en orden descendente según el número de observaciones asociadas, y luego se sobremuestran individualmente una a una usando la versión binaria de RBO.

2.1.2 Submuestreo de la clase mayoritaria

El submuestreo implica reducir la cantidad de muestras de la clase mayoritaria para equilibrar la distribución de clases. Esta técnica es efectiva para grandes conjuntos de datos, pero puede conllevar a la pérdida de información importante.

RUS De forma paralela a su contra parte para sobremuestreo, este método consiste en eliminar instancias de la clase mayoritaria de forma aleatoria hasta alcanzar un criterio de parada determinado.

ENN El algoritmo de Edición por Vecinos Más Cercanos (Wilson, 1972) opera revisando cada instancia de conjunto de datos y evaluando su conformidad con sus vecinos más cercanos. Primero, se identifican los k vecinos más cercanos de cada muestra en el conjunto de datos. Luego, se compara la etiqueta de cada muestra con las etiquetas de sus vecinos más cercanos; si la etiqueta de una muestra difiere significativamente de la mayoría de sus vecinos, esto indica que la muestra podría ser ruido o estar mal etiquetada. Las muestras que no se alinean bien con sus vecinos se eliminan.

Tomek links El método propuesto por Batista et al. (2004) emplea los enlaces Tomek (Tomek, 1976), que consisten en pares de puntos que son los vecinos más cercanos entre sí pero que no comparten la misma etiqueta de clase. Este método puede usarse para submuestreo o limpieza de datos: como método de submuestreo, solo se eliminan los ejemplos que pertenecen a la clase mayoritaria, y como método de limpieza de datos, se eliminan los ejemplos de ambas clases.

NearMiss 1, 2 y 3 La premisa fundamental de NearMiss (Mani and Zhang, 2003) es que al mantener las muestras de la clase mayoritaria más relevantes para la frontera de decisión, se puede mejorar la eficacia del clasificador sin retener todo el conjunto de datos desbalanceado. Las diferencias entre las versiones de NearMiss radican en cómo cada una define la "relevancia" y selecciona las muestras de la clase mayoritaria para ser retenidas o descartadas:

NearMiss-1 conserva muestras de la clase mayoritaria que tienen la menor distancia promedio a los k ejemplos más cercanos de la clase minoritaria.

NearMiss-2, en contraste, selecciona muestras de la clase mayoritaria que tienen la menor distancia promedio a los k ejemplos más lejanos de la clase minoritaria.

NearMiss-3 adopta el enfoque con mejor rendimiento. Para cada muestra de la clase minoritaria, conserva los k vecinos más cercanos pertenecientes a la clase mayoritaria. Después, se eliminan las muestras de la clase mayoritaria con la mayor distancia promedio a sus k vecinos más cercanos.

Cluster-centroids Lin et al. (2017) plantean realizar un agrupamiento (clustering), usando k-NN de las muestras de la clase mayoritaria y luego reemplazar estos grupos con los centroides de los clusters. Así, se conserva información estructural de la clase mayoritaria mientras se reduce su tamaño.

2.1.3 Métodos híbridos

SMOTE+Tomek Batista et al. (2004) propone aplicar enlaces Tomek al conjunto de entrenamiento sobre-muestreado como método de limpieza de datos. Así, en lugar de eliminar solo los ejemplos de la clase mayoritaria que forman enlaces Tomek, se eliminan ejemplos de ambas clases. Para ello, el conjunto de datos original se sobremuestra con Smote y, a continuación, se identifican los enlaces Tomek y se eliminan, lo que produce un conjunto de datos equilibrado con grupos de clases bien definidos.

SMOTE+ENN Siguiendo una filosofía similar a SMOTE+Tomek, los mismos autores apuntan que ENN tiende a eliminar más ejemplos que los enlaces Tomek, por lo que se espera que proporcione una limpieza de datos más profunda. Puesto que se utiliza para eliminar ejemplos de ambas clases, cualquier ejemplo mal clasificado por sus k vecinos más cercanos se elimina del conjunto de datos (Batista et al., 2004).

2.2 Técnicas a nivel algorítmico

Otra forma de atacar el desbalanceo de clases es durante la fase de modelado. El problema es que esta aproximación requiere de conocimiento experto para la adecuada selección de modelos y estrategias acordes al problema a resolver

2.2.1 Selección de modelos apropiados

Boosting se enfoca en construir secuencialmente una serie de modelos, donde cada modelo subsiguiente intenta corregir los errores cometidos por los modelos anteriores.

AdaBoost (Freund and Schapire, 1997) construye iterativamente un modelo combinando clasificadores débiles. Comienza asignando pesos iguales a todos los ejemplos de entrenamiento. En cada iteración, entrena un clasificador débil, generalmente un árbol de decisión, con la distribución de pesos actual. Luego, calcula el error ponderado de este clasificador y lo emplea para calcular su coeficiente, el cual indica la importancia del clasificador en el modelo final.

El paso crucial es la actualización de los pesos de los ejemplos de entrenamiento: los ejemplos mal clasificados por el clasificador débil actual reciben un mayor peso, mientras que los pesos de los ejemplos correctamente clasificados se reducen. Esto hace que el algoritmo se enfoque en los ejemplos más difíciles en iteraciones subsiguientes.

Finalmente, el modelo de AdaBoost es una suma ponderada de todos los clasificadores débiles, donde cada clasificador aporta según su coeficiente. Este enfoque asegura que los clasificadores que mejoran significativamente el rendimiento en ejemplos difíciles tengan más influencia en la decisión final.

SMOTEBoost El método planteado por Chawla et al. (2003) funciona en iteraciones, como AdaBoost, pero con un paso adicional crítico: antes de entrenar cada clasificador débil, SMOTEBoost aplica SMOTE al conjunto de entrenamiento para generar ejemplos sintéticos de la clase minoritaria, lo que ayuda a equilibrar la distribución de clases, haciendo que el clasificador débil se enfoque más en la clase minoritaria. Después de la generación de ejemplos sintéticos, SMOTEBoost procede exactamente como AdaBoost.

RUSBoost De forma paralela a SMOTEBoost, este método (Seiffert et al., 2009) combina AdaBoost con un método de preprocesado de datos (RUS). El procedimiento es idéntico a SMOTEBoost, pero con dos diferencias: primero, se sustituye la técnica de sobremuestreo por RUS y, segundo, no es necesario asignar nuevos pesos a las instancias debido a que ahora estamos realizando submuestreo aleatorio. Basta con normalizar los pesos de las instancias restantes en el nuevo conjunto de datos con respecto a su suma total de pesos.

Bagging Bootstrap Aggregating, (Breiman, 1996) es una técnica de ensamblaje en la que se construyen múltiples modelos independientes, generalmente del mismo tipo, y luego se combina su salida para formar una única predicción final. Cada uno de estos modelos se entrena en una muestra aleatoria con reemplazo del conjunto original.

SMOTEBagging (Wang and Yao, 2009) aprovecha la capacidad de SMOTE para equilibrar las clases a través de la generación de ejemplos sintéticos para la clase minoritaria y se combina con la robustez del ensamblaje de Bagging. En SmoteBagging, antes de entrenar cada modelo individual dentro del ensamblaje, se aplica SMOTE a la muestra de bootstrap correspondiente. Esto asegura que cada modelo se entrene en un conjunto de datos donde las clases están equilibradas.

RBB Roughly balanced bagging (Hido et al., 2009) introduce una etapa de preprocesamiento antes del entrenamiento de cada modelo. Este preprocesamiento implica una "rotación" de los datos, es decir, una transformación lineal que cambia la representación del espacio de características. A la hora de seleccionar los subconjuntos para entrenar cada modelo, se fija el número de muestras de la clase minoritaria igual al número del conjunto de datos original. Si se muestrean sin reemplazo, todos los ejemplos positivos estarán contenidos en todos los subconjuntos muestreados. En cambio, el número de muestras negativas se determina probabilísticamente utilizando una distribución binomial negativa, cuyos parámetros son el número de ejemplos minoritarios (es decir, positivos) y la probabilidad de éxito $q = 0,5$. La clave es que los ejemplos de ambas clases se extraen con la misma probabilidad, pero solo varía el tamaño de las muestras negativas, y el número de muestras positivas se mantiene constante.

3 Conclusiones y líneas futuras

Siguiendo la taxonomía propuesta, este documento recoge una visión general, con atención al detalle, de las técnicas más usadas a la hora de lidiar con conjuntos de datos desbalanceados en la tarea de clasificación, así como algunos de sus puntos fuertes y débiles. Como posibles líneas futuras, parece que la investigación, ha ido creciendo hacia la aplicación del enfoque conexionista moderno para la solución de este tipo de problemas (Zhou and Liu, 2005). Prueba de ello es que ya se han propuesto varias funciones de error como MFE, MSFE (Wang et al., 2016) y VISAL (Sivapuram et al., 2023), así como el uso de técnicas de aprendizaje por refuerzo (Lin et al., 2020), para sensibilizar a las redes neuronales en su entrenamiento respecto al error de clasificación de instancias minoritarias. Por otro lado, también se investiga en el uso directo de modelos profundos a la hora de generar muestras sintéticas (Dablain et al., 2022).

References

Lida Abdi and Sattar Hashemi. To combat multi-class imbalanced problems by means of over-sampling techniques. *IEEE transactions on Knowledge and Data Engineering*, 28(1):238–251, 2015.

- Erin L Allwein, Robert E Schapire, and Yoram Singer. Reducing multiclass to binary: A unifying approach for margin classifiers. *Journal of machine learning research*, 1(Dec):113–141, 2000.
- Gustavo EAPA Batista, Ronaldo C Prati, and Maria Carolina Monard. A study of the behavior of several methods for balancing machine learning training data. *ACM SIGKDD explorations newsletter*, 6(1):20–29, 2004.
- Cigdem Beyan and Robert Fisher. Classifying imbalanced data sets using similarity based hierarchical decomposition. *Pattern Recognition*, 48(5):1653–1672, 2015.
- Paula Branco and Rita P Torgo, Luís an d Ribeiro. A survey of predictive modeling on imbalanced domains. *ACM computing surveys (CSUR)*, 49(2):1–50, 2016.
- Leo Breiman. Bagging predictors. *Machine learning*, 24:123–140, 1996.
- Chumphol Bunkhumpornpat, Krung Sinapiromsaran, and Chidchanok Lursinsap. Safe-level-smote: Safe-level-synthetic minority over-sampling technique for handling the class imbalanced problem. In *Advances in Knowledge Discovery and Data Mining: 13th Pacific-Asia Conference, PAKDD 2009 Bangkok, Thailand, April 27-30, 2009 Proceedings 13*, pages 475–482. Springer, 2009.
- Nitesh V Chawla, Kevin W Bowyer, Lawrence O Hall, and W Philip Kegelmeyer. Smote: synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16:321–357, 2002.
- Nitesh V Chawla, Aleksandar Lazarevic, Lawrence O Hall, and Kevin W Bowyer. Smoteboost: Improving prediction of the minority class in boosting. In *Knowledge Discovery in Databases: PKDD 2003: 7th European Conference on Principles and Practice of Knowledge Discovery in Databases, Cavtat-Dubrovnik, Croatia, September 22-26, 2003. Proceedings 7*, pages 107–119. Springer, 2003.
- Damien Dablain, Bartosz Krawczyk, and Nitesh V Chawla. Deepsmote: Fusing deep learning and smote for imbalanced data. *IEEE Transactions on Neural Networks and Learning Systems*, 2022.
- Vitor Miguel Saraiva Esteves. Techniques to deal with imbalanced data in multi-class problems: A review of existing methods. *PQDT-Global*, 2020.
- Yoav Freund and Robert E Schapire. A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of computer and system sciences*, 55(1):119–139, 1997.
- Mikel Galar, Alberto Fernandez, Edurne Barrenechea, Humberto Bustince, and Francisco Herrera. A review on ensembles for the class imbalance problem: bagging-, boosting-, and hybrid-based approaches. *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)*, 42(4):463–484, 2011.
- Guo Haixiang, Li Yijing, Jennifer Shang, Gu Mingyun, Huang Yuanyue, and Gong Bing. Learning from class-imbalanced data: Review of methods and applications. *Expert systems with applications*, 73:220–239, 2017.
- Hui Han, Wen-Yuan Wang, and Bing-Huan Mao. Borderline-smote: a new over-sampling method in imbalanced data sets learning. In *International conference on intelligent computing*, pages 878–887. Springer, 2005.
- Trevor Hastie and Robert Tibshirani. Classification by pairwise coupling. *Advances in neural information processing systems*, 10, 1997.
- Haibo He and Eduardo A Garcia. Learning from imbalanced data. *IEEE Transactions on knowledge and data engineering*, 21(9):1263–1284, 2009.
- Haibo He, Yang Bai, Eduardo A Garcia, and Shutao Li. Adasyn: Adaptive synthetic sampling approach for imbalanced learning. In *2008 IEEE international joint conference on neural networks (IEEE world congress on computational intelligence)*, pages 1322–1328. Ieee, 2008.
- Shohei Hido, Hisashi Kashima, and Yutaka Takahashi. Roughly balanced bagging for imbalanced data. *Statistical Analysis and Data Mining: The ASA Data Science Journal*, 2(5-6):412–426, 2009.
- György Kovács. Smote-variants: A python implementation of 85 minority oversampling techniques. *Neurocomputing*, 366:352–354, 2019.

- Michał Koziarski, Bartosz Krawczyk, and Michał Woźniak. Radial-based oversampling for noisy imbalanced data classification. *Neurocomputing*, 343:19–33, 2019.
- Bartosz Krawczyk, Michał Woźniak, and Francisco Herrera. On the usefulness of one-class classifier ensembles for decomposition of multi-class problems. *Pattern Recognition*, 48(12):3969–3982, 2015.
- Bartosz Krawczyk, Michał Koziarski, and Michał Woźniak. Radial-based oversampling for multiclass imbalanced data classification. *IEEE transactions on neural networks and learning systems*, 31(8):2818–2831, 2019.
- Enlu Lin, Qiong Chen, and Xiaoming Qi. Deep reinforcement learning for imbalanced classification. *Applied Intelligence*, 50:2488–2502, 2020.
- Wei-Chao Lin, Chih-Fong Tsai, Ya-Han Hu, and Jing-Shang Jhang. Clustering-based undersampling in class-imbalanced data. *Information Sciences*, 409:17–26, 2017.
- Victoria López, Alberto Fernández, Salvador García, Vasile Palade, and Francisco Herrera. An insight into classification with imbalanced data: Empirical results and current trends on using data intrinsic characteristics. *Information sciences*, 250:113–141, 2013.
- Inderjeet Mani and I Zhang. knn approach to unbalanced data distributions: a case study involving information extraction. In *Proceedings of workshop on learning from imbalanced datasets*, volume 126, pages 1–7. ICML, 2003.
- Ryan Rifkin and Aldebaro Klautau. In defense of one-vs-all classification. *The Journal of Machine Learning Research*, 5:101–141, 2004.
- Chris Seiffert, Taghi M Khoshgoftaar, Jason Van Hulse, and Amri Napolitano. Rusboost: A hybrid approach to alleviating class imbalance. *IEEE transactions on systems, man, and cybernetics-part A: systems and humans*, 40(1):185–197, 2009.
- Arun Kumar Sivapuram, Vaishnavi Ravi, Gowtham Senthil, Rama Krishna Gorthi, et al. Visal—a novel learning strategy to address class imbalance. *Neural Networks*, 161:178–184, 2023.
- Ivan Tomek. Two modifications of cnn. 1976.
- Shoujin Wang, Wei Liu, Jia Wu, Longbing Cao, Qinxue Meng, and Paul J Kennedy. Training deep neural networks on imbalanced data sets. In *2016 international joint conference on neural networks (IJCNN)*, pages 4368–4374. IEEE, 2016.
- Shuo Wang and Xin Yao. Diversity analysis on imbalanced data sets by using ensemble models. In *2009 IEEE symposium on computational intelligence and data mining*, pages 324–331. IEEE, 2009.
- Shuo Wang and Xin Yao. Multiclass imbalance problems: Analysis and potential solutions. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 42(4):1119–1130, 2012.
- Dennis L Wilson. Asymptotic properties of nearest neighbor rules using edited data. *IEEE Transactions on Systems, Man, and Cybernetics*, (3):408–421, 1972.
- Ting-Fan Wu, Chih-Jen Lin, and Ruby Weng. Probability estimates for multi-class classification by pairwise coupling. *Advances in Neural Information Processing Systems*, 16, 2003.
- Jie Zhou, Hanchuan Peng, and Ching Y Suen. Data-driven decomposition for multi-class classification. *Pattern Recognition*, 41(1):67–76, 2008.
- Zhi-Hua Zhou and Xu-Ying Liu. Training cost-sensitive neural networks with methods addressing the class imbalance problem. *IEEE Transactions on knowledge and data engineering*, 18(1):63–77, 2005.