




Dealing with imbalanced clasifcation - SOTA

Juan García Santos
juan.gsantos@alumnos.upm.es

Machine Learning – MUIA 2023







Técnicas a nivel de datos - Sobremuestreo


ROS

- Random Over-sampling
- No genera muestras nuevas

SMOTE

- Synthetic minority over-sampling technique
- Parámetro de distancia k para selección de vecinos
- Genera nuevas instancias en la recta que une las dos muestras seleccionadas
- Malo para conjuntos solapados, con mucho ruido y pocas instancias

Imbalanced Data Sets Classification Based on SVM for Sand-Dust Storm Warning - Scientific Figure on ResearchGate.



Técnicas a nivel de datos - Sobremuestreo

Borderline SMOTE

- Especial atención a las fronteras de decisión
- Sobremuestrea solo en base a instancias “en peligro”
- Hay 2 versiones

SafeLevel SMOTE

- Intenta sobremuestrear con poco ruido
- Introduce el concepto de “nivel de seguridad”
- Genera muestras en zonas “muy seguras”

ADASYN

- Genera muestras en base a instancias difíciles de aprender
- El número generado depende de los vecinos
- Instancias rodeadas de la clase contraria se usan más

Técnicas a nivel de datos - Sobremuestreo

RBO



- Creado para suplir las debilidades de SMOTE
- Emplea funciones de base radial para estimar un valor de potencial en cada punto
- Existen dos criterios de optimización

MDO

- Usa la distancia de Mahalanobis para medir la distancia entre muestras
- Muy útil en espacios correlacionados y de alta dimensionalidad
- Cada muestra de la clase minoritaria recibe un peso de selección
- Se generan muestras en el contorno de la elipse en que pasa por la muestra


$$D_M(x, \mu) = \sqrt{(x - \mu)^T S^{-1} (x - \mu)}.$$

(Abdi and Hashemi (2015))





Técnicas a nivel de datos - Sobremuestreo


M. Koziarski, B. Krawczyk and M. Woźniak / Neurocomputing 343 (2019) 19–33



M. Koziarski, B. Krawczyk and M. Woźniak / Neurocomputing 343 (2019) 19–33



(Abdi and Hashemi (2015))



Técnicas a nivel de datos - Submuestreo

RUS

- Elimina instancias aleatoriamente
- Hasta cumplir un criterio de parada

ENN

- Se identifican los k vecinos más cercanos de cada muestra
- Si la mayoría de vecinos son de la clase opuesta, se elimina la instancia

Tomek Links

- Se identifican los enlaces Tomek
- Para submuestreo se elimina medio enlace
- Para limpieza se elimina el enlace entero




Técnicas a nivel de datos - Submuestreo


Cluster-Centroid

- Clustering de las muestras de la clase mayoritaria
- Sustitución de cada cluster por su centoride

NearMiss 1, 2, 3

- Busca mantener las muestras de la clase mayoritaria más relevantes para la frontera de decisión
- Hay 3 versiones:





Técnicas a nivel de datos - Híbridos


SMOTE-Tomek

- Primero se realiza sobremuestreo con SMOTE
- Después se limpia el resultado en base a los enlaces Tomek

SMOTE-ENN

- ENN elimina más instancias que Tomek, así que lo sustituimos para un filtrado más agresivo

Imbalanced classification



Técnicas a nivel algorítmico - Boosting

AdaBoost

- Entrena clasificadores débiles de forma secuencial
- Asigna pesos a las muestras (a mayor, pero clasificado)
- Clasificadores enfocados en ejemplos mal clasificados

SMOTEBoost

- Como AdaBoost pero se aplica SMOTE al conjunto de entrenamiento de cada clasificador débil

RUSBoost

- Como SMOTEBoost, pero sustituye SMOTE por RUS
- No asigna nuevos pesos a las instancias en cada iteración, solo los normaliza

Técnicas a nivel algorítmico - Bagging

RBB

- Cambia la selección de muestras de Bootstrap.
- Los ejemplos de ambas clases se extraen con la misma probabilidad, pero solo varía el tamaño de las muestras negativas.

SMOTE-Bagging

- Antes de entrenar cada modelo individual dentro del ensamblaje, se aplica SMOTE a la muestra de bootstrap correspondiente.

Conclusiones y líneas futuras

Conclusiones

- Campo MUY amplio, muchas aproximaciones a la resolución del problema
- Se pueden combinar aproximaciones de ambas ramas simultáneamente
- El nivel algorítmico requiere conocimiento experto del funcionamiento a “bajo nivel”
- El nivel de datos requiere conocimiento experto del conjunto a emplear

Líneas Futuras

- Aprendizaje por refuerzo ((Lin et al., 2020))
- Nuevas funciones de error para las RNN (MFE, MSFE (Wang et al., 2016) y VISAL (Sivapuram et al., 2023))
- Uso de modelos profundos para la generación de muestras sintéticas (DeepSMOTE (Dablain et al., 2022))

Referencias de la presentación

- Lida Abdi and Sattar Hashemi. To combat multi-class imbalanced problems by means of over-sampling techniques. *IEEE transactions on Knowledge and Data Engineering*, 28(1):238–251, 2015.
- Gustavo EAPA Batista, Ronaldo C Prati, and Maria Carolina Monard. A study of the behavior of several methods for balancing machine learning training data. *ACM SIGKDD explorations newsletter*, 6(1):20–29, 2004.
- Chumphol Bunkhumpornpat, Krung Sinapiromsaran, and Chidchanok Lursinsap. Safe-level-smote: Safe-levelsynthetic minority over-sampling technique for handling the class imbalanced problem. In *Advances in Knowledge Discovery and Data Mining: 13th Pacific-Asia Conference, PAKDD 2009 Bangkok, Thailand, April 27-30, 2009 Proceedings 13*, pages 475–482. Springer, 2009.
- Nitesh V Chawla, Kevin W Bowyer, Lawrence O Hall, and W Philip Kegelmeyer. Smote: synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16:321–357, 2002.
- Nitesh V Chawla, Aleksandar Lazarevic, Lawrence O Hall, and Kevin W Bowyer. Smoteboost: Improving prediction of the minority class in boosting. In *Knowledge Discovery in Databases: PKDD 2003: 7th European Conference on Principles and Practice of Knowledge Discovery in Databases, Cavtat-Dubrovnik, Croatia, September 22-26, 2003. Proceedings 7*, pages 107–119. Springer, 2003.
- Damien Dablain, Bartosz Krawczyk, and Nitesh V Chawla. Deepsmote: Fusing deep learning and smote for imbalanced data. *IEEE Transactions on Neural Networks and Learning Systems*, 2022.
- Yoav Freund and Robert E Schapire. A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of computer and system sciences*, 55(1):119–139, 1997.
- Hui Han, Wen-Yuan Wang, and Bing-Huan Mao. Borderline-smote: a new over-sampling method in imbalanced data sets learning. In *International conference on intelligent computing*, pages 878–887. Springer, 2005.
- Haibo He, Yang Bai, Eduardo A Garcia, and Shutao Li. Adasyn: Adaptive synthetic sampling approach for imbalanced learning. In *2008 IEEE international joint conference on neural networks (IEEE world congress on computational intelligence)*, pages 1322–1328. Ieee, 2008.
- Shohei Hido, Hisashi Kashima, and Yutaka Takahashi. Roughly balanced bagging for imbalanced data. *Statistical Analysis and Data Mining: The ASA Data Science Journal*, 2(5-6):412–426, 2009.
- Michal Koziarski, Bartosz Krawczyk, and Michał Wozniak. Radial-based oversampling for noisy imbalanced data classification. *Neurocomputing*, 343:19–33, 2019.
- Wei-Chao Lin, Chih-Fong Tsai, Ya-Han Hu, and Jing-Shang Jhang. Clustering-based undersampling in classimbalanced data. *Information Sciences*, 409:17–26, 2017.
- Inderjeet Mani and I Zhang. knn approach to unbalanced data distributions: a case study involving information extraction. In *Proceedings of workshop on learning from imbalanced datasets*, volume 126, pages 1–7. ICML, 2003.
- Chris Seiffert, Taghi M Khoshgoftaar, Jason Van Hulse, and Amri Napolitano. Rusboost: A hybrid approach to alleviating class imbalance. *IEEE transactions on systems, man, and cybernetics-part A: systems and humans*, 40(1):185–197, 2009.
- Arun Kumar Sivapuram, Vaishnavi Ravi, Gowtham Senthil, Rama Krishna Gorthi, et al. Visal—a novel learning strategy to address class imbalance. *Neural Networks*, 161:178–184, 2023.
- Shuo Wang and Xin Yao. Diversity analysis on imbalanced data sets by using ensemble models. In *2009 IEEE symposium on computational intelligence and data mining*, pages 324–331. IEEE, 2009.
- Dennis L Wilson. Asymptotic properties of nearest neighbor rules using edited data. *IEEE Transactions on Systems, Man, and Cybernetics*, (3):408–421, 1972.
- Zhi-Hua Zhou and Xu-Ying Liu. Training cost-sensitive neural networks with methods addressing the class imbalance problem. *IEEE Transactions on knowledge and data engineering*, 18(1):63–77, 2005.

THE END
