

Review of Neuro-Symbolic Integration SOTA

Juan García Santos

MUIA

UPM

Madrid, España

juan.g Santos@alumnos.upm.es

Pelayo Rodriguez Gonzalez

MUIA

UPM

Madrid, España

pelayo.rodriguezgonz@alumnos.upm.es

Abstract—Este documento aborda las dos corrientes principales de la inteligencia artificial: las aproximaciones simbólicas y conexionistas. Mientras la primera se distingue por su capacidad de interpretación y eficacia en el razonamiento, la segunda es reconocida por su expresividad y habilidad para identificar y representar patrones en conjuntos de datos. El foco principal de este campo es desarrollar un enfoque integrador que combine las ventajas de ambas corrientes, minimizando sus limitaciones y manteniendo o mejorando el rendimiento de los sistemas existentes. Dicha motivación surge de diversas fuentes, destacando recientemente el creciente interés en modelos de redes neuronales profundas, con especial atención a su veracidad, seguridad e interpretabilidad.

En la presente revisión se emplea una taxonomía existente [1] para dar a conocer cuáles son los focos de esfuerzo actual de los investigadores, así como posibles líneas futuras de desarrollo. Para ello no solo se explican las principales líneas de investigación, sino también sus vertientes más relevantes e incluso se introducen los artículos y productos más relevantes asociados a cada rama, todo con el objetivo de ejemplificar las explicaciones y dar una vista general del "paisaje" actual de la integración neuro-simbólica.

Index Terms—Integración neurosimbólica, representación sub-simbólica, DNNs, conocimiento

I. INTRODUCCIÓN

La principal diferencia entre los dos enfoques de la inteligencia artificial se encuentra en como entienden cada uno de ellos el proceso cognitivo del cerebro para poder así adaptarlo a las máquinas. El simbolismo entiende que el punto principal que mueve la inteligencia humana son las representaciones de los conceptos y objetos del mundo, es decir, la simbología y por ello el proceso cognitivo viene marcado por la manipulación de estas representaciones. El manejo de los símbolos que rige el simbolismo suele darse gracias a la utilización de un conjunto de reglas y operaciones lógicas, las cuáles permiten llegar a las conclusiones necesarias. Este enfoque más tradicional de ver la inteligencia enfatiza los razonamientos lógico y deductivo, ya que utiliza un conjunto de sistemas formales que permiten definir estas representaciones y el conjunto de reglas para poder inferir nuevo conocimiento o llegar a conclusiones gracias al conocimiento que ya se tenía.

Por otro lado, el enfoque conexionista se encuentra basado en la idea biológica de la inteligencia ya que cualquier conclusión obtenida gracias al proceso cognitivo se va a conseguir gracias a la conexión de un conjunto de células denominadas células que son capaces de procesar la información que les

llega y transmiten los resultados a las siguientes con las que están conectadas. Por ello, la principal técnica que utiliza este enfoque son las redes de neuronas artificiales, ya que estas consisten en grupos de nodos o neuronas interconectados formando capas y que van procesando la información a medida que se avanza por la red. Esto hace que la inteligencia ahora venga marcada por el proceso de aprender los pesos que se dan a cada una de estas conexiones utilizando el conocimiento que se tiene gracias a métodos como la retropropagación de gradiente y así ir disminuyendo el error con el que posteriormente se realizará el proceso cognitivo y se obtendrán las nuevas soluciones.

II. INTEGRACIÓN NEURO-SIMBÓLICA

Cuando se necesita tomar la decisión de cuando utilizar una estrategia u otra para la resolución de un problema, hay que razonar en cuál es la situación que se quiere resolver y que características tiene, ya que cada una de estas nos permite realizar una serie de cosas u otras. El enfoque simbólico nos permite obtener resultados gracias al uso de una cantidad muy pequeña de datos de entrada, ya que gracias al uso del conjunto de reglas se puede ir infiriendo nuevos datos y por ello ampliar ese conocimiento inicial; además gracias al uso de un grupo de reglas lógicas definido, se puede obtener una manera fácil una explicación de porque se ha llegado a ese resultado ya que lo único que hay que comprender es el proceso de aplicación de cada una de las reglas que se ha llevado a cabo. En cuanto al conexionismo, este nos va a permitir modelos que disfrutan de las ventajas del razonamiento inductivo y de la generalización gracias a que en el proceso de entrenamiento de estas redes se aprenden patrones estadísticos de los datos para utilizarlos en el proceso de razonamiento. Además, estos modelos son tolerantes a los fallos que se cometen, ya que estos utilizan representaciones sub-simbólicas de los conceptos, como pueden ser los continuous embedding vectors, que son un conjunto de características que definen el problema, en vez de utilizar las representaciones simbólicas que contienen el significado literal de cada concepto.

Pero no todo son cosas buenas en el uso de los dos enfoques, ya que estos presentan una serie de desventajas, como es en el caso de los modelos conexionistas el nivel tan bajo de generalización composicional que presentan y que no les permite la habilidad de resolver cualquier problema de manera correcta. Estos modelos también presentan el problema de que

son ineficientes en datos ya que necesitan una gran cantidad de datos etiquetados para poder obtener buenas conclusiones y de que al trabajar sin ningún tipo de variable lógica y al ser tan opacos no presentan ningún tipo de comprensibilidad y por lo tanto es muy difícil analizar el porque de la solución. En el caso del simbolismo ahora se utilizan representaciones discretas que utilizan el significado literal y no un embedding de este, por lo que, cuando se utilicen datos que estén un poco alterados o que exista la presencia de ruido estos sistemas o van a encontrar maneras de saltar estas complicaciones y darán malos resultados. Además, al basar todo el razonamiento en un conjunto concreto de reglas, para construir estos modelos se necesita una gran comprensión del problema por la persona que los diseña y un proceso largo de ajustado que consiga representar correctamente la realidad.

Vistas las ventajas y desventajas de cada sistema, es aparente que las dos visiones se complementan muy bien. En particular, las redes neuronales sobresalen a la hora de encontrar patrones entre datos, y lo logran de una forma robusta frente al ruido. Por otro lado, los modelos simbólicos se caracterizan por su transparencia y proximidad a los esquemas de razonamiento humano.

A continuación, se desarrollan 6 conjuntos de aproximaciones identificadas en la literatura existente a la hora de integrar sistemas con representaciones simbólicas y sub-simbólicas:

A. Tipo 1: Symbolic Neuro Symbolic

El primer conjunto de fusiones neurosimbólicas lo representan las que utilizan como entrada y como salida de un modelo conexionista los símbolos, por ello se les ha denominado “Symbolic Neuro Symbolic”. Este conjunto de modelos representa el procedimiento estándar actual para muchos de los métodos de aprendizaje en muchos campos como son el procesamiento del lenguaje natural o la manipulación de grafos, ya que en estos casos se necesita trabajar con información simbólica como lo son las palabras o los grafos de conocimiento. Este conjunto de sistemas va a coger las representaciones simbólicas que tiene como conocimiento y va a obtener una nueva representación de estas, pero ahora en forma vectorial (embedding) para que puedan ser comprendidas por las arquitecturas neuronales que las van a procesar. En el caso de la salida volverá a ocurrir la misma situación ya que los resultados de una arquitectura conexionista son un conjunto de valores numéricos que hay que volver a transformar en la representación simbólica que queremos como conclusión final.




Fig. 1. Representación de los modelos de Tipo 1

Algunos ejemplos de este tipo de representaciones son los “word2vec” [2], que buscan encontrar representaciones

que sean parecidas si pertenecen a palabras que se utilizan en contextos parecidos o “GloVe” [3] cuando se utilizan estadísticas de co-ocurrencia de las palabras en el texto para obtenerlas. El modelo de representación “word2vec” calcula la representación de una palabra basándose en que contextos aparece dentro del texto, es decir, que otras palabras suele tener cerca tanto antes como después de esta, para así poder posteriormente relacionar las palabras gracias a como se suelen utilizar y con ello poder realizar operaciones como “reina = rey–hombre”. En cambio, el modelo de representación “GloVe” encuentra una representación con más fuerza semántica ya que va a utilizar estadísticas globales de co-ocurrencia para analizar la frecuencia en la que aparecen juntas distintas palabras y va a necesitar de textos mucho más grandes para ser entrenado.

En cuanto a un ejemplo de arquitectura de este tipo 1 de unión neurosimbólica y que actualmente se encuentra muy de moda es el caso de GPT-3 [4], el cuál al ser un modelo generativo, va a recibir texto como entrada un conjunto de palabras (símbolos) y va a ser capaz de generar un nuevo texto respondiendo a esta entrada. Este modelo en la primera fase que hemos analizado antes, que busca transformar la entrada del lenguaje simbólico al lenguaje sub-simbólico (vectores), va a usar un sistema de embedding un poco diferente ya que ahora cada representación no solo contiene el significado de la palabra con la que está relacionada, sino que va a tener información sobre todas las palabras que hay en la frase en la que se encuentra. Una vez realizados estos positional embeddings, la arquitectura conexionista que utiliza no va a ser una red neuronal tradicional sino un modelo basado en Transformers, el cuál usa una pila de encoders para procesar la entrada en paralelo y una pila de decoders que generará el resultado palabra a palabra. El resultado de esta arquitectura consiste en un vector con probabilidades de que la solución sea cada palabra, por lo que para volver a conseguir una representación simbólica se aplica una soft-max que se encarga de seleccionar que palabra se está generando realmente.

B. Tipo 2: Symbolic[Neuro]

Ahora en este nuevo conjunto de modelos neurosimbólicos vamos a tener una primera versión de un sistema híbrido entre los dos enfoques, ya que los del tipo anterior no utilizaban ningún modelo de tipo simbólico en el proceso y solo se utilizaban los símbolos como entrada y salida del modelo conexionista. En las arquitecturas de este grupo denominado “Symbolic[Neuro]”, como se puede intuir gracias al nombre, se va a utilizar un modelo de tipo simbólico como base principal y este modelo va a utilizar el conexionista como una subrutina para resolver el problema que se necesite. Por ello, estos modelos van a tener dos partes poco relacionadas entre sí, en la que un modelo base de tipo simbólico va a utilizar la otra parte que es la conexionista para que le resuelva una tarea en concreto que luego va a necesitar para obtener la solución final.

Una implementación conocida de este tipo de sistemas se trata del programa de desarrollado por DeepMind AI-




Fig. 2. Representación de los modelos de Tipo 2

phaGo [5]. Este sistema implementa una técnica de búsqueda simbólica denominada Búsqueda de Árbol Monte Carlo (MCTS) que se encarga de encontrar soluciones óptimas en ciertos problemas de decisión como en este caso que busca encontrar los mejores movimientos en el juego GO. El MCTS, va a utilizar una estructura simbólica como es un grafo, para ir analizando las cadenas de movimientos y encontrar cuál es el mejor a realizar en cada momento, por ello, aquí es donde entra el modelo conexionista. Este modelo, aunque la decisión la tome finalmente el modelo simbólico, es el que se va a encargar de ofrecer la información heurística al sistema. Esta información consiste en evaluar las posiciones en el tablero y predecir próximos movimientos gracias a entrenar una red neuronal profunda gracias a una base de datos con partidas realizadas anteriormente y refinado con un proceso de aprendizaje por refuerzo en el que el sistema jugaba consigo mismo. Finalmente, este sistema toma la decisión gracias a un conjunto de estrategias y tácticas de estilo simbólico, que se ayudan de la información predicha por la red neuronal.

Otro sistema que podemos englobar en este tipo de neuro-simbolismo se trata del modelo de aprendizaje y generalización de reglas composicionales Ness [6]. Este sistema utiliza una red de generación secuencia-a-secuencia (seq2seq) de las reglas simbólicas y se complementa con una máquina de pila simbólica para soportar la recursión y la manipulación de secuencias. En este modelo, el trazado de ejecución, que es el proceso por el cual el modelo opera y toma decisiones, es generado por una red neuronal. Por ello, el sistema base de tipo simbólico es el que va a llamar a la red neuronal para mejorar su capacidad de generalización y manejo de estructuras y secuencias complejas.

Por último, otro sistema interesante que utiliza este tipo de fusión entre los dos enfoques de la inteligencia artificial se trata de PLANS (Program Learning from Neurally inferred Specifications) [7] que consiste en un sistema avanzado basado en reglas para la síntesis de programas basados en observaciones visuales sin procesar. Al tener como entrada conceptos que son visuales, para poder comprenderlos correctamente este modelo simbólico basado en reglas, necesita de un módulo de percepción neuronal que se encargue de interpretar y transformar estos datos en las representaciones abstractas que sí que entiende el sistema y por ello van a servir como base de conocimiento del sistema. Una vez que se obtienen el conocimiento inicial gracias a este módulo conexionista, se va aplicando un proceso de aplicación de las reglas del modelo para obtener el resumen que se busca.

C. Tipo 3: Neuro—Symbolic

Continuando con la taxonomía que se está utilizando para categorizar los modelos neurosimbólicos aparece el siguiente conjunto de arquitecturas que van a volver a contener un sistema híbrido entre los dos enfoques, pero con el añadido de que ahora las dos partes van a trabajar a la vez para poder obtener el resultado. Las arquitecturas de tipo Neuro—Simbólico van a utilizar un modelo de cada enfoque para que cada uno de ellos se encargue de realizar un conjunto de tareas distintas pero complementarias para poder obtener entre las dos partes el resultado final. Las arquitecturas de tipo 2 utilizaban la parte conexionista como una subrutina de la parte simbólica teniendo una dependencia la primera de la segunda, pero ahora en este caso las dos van a trabajar como corutinas, es decir, van a colaborar las dos partes para que cada una trabajando en su parte se consiga obtener el mejor resultado. Este nuevo enfoque de unión va a permitir dividir la tarea, que tiene que resolver nuestro proceso cognitivo artificial, en dos partes distintas y asignar a cada modelo la lista de tareas que mejor se adapte al enfoque tradicional que represente.



Fig. 3. Representación de los modelos de Tipo 3

Uno de los principales ejemplos de este tipo de sistemas se encuentra en los sistemas de síntesis de programas que utilizan los modelos neuronales para generar los programas simbólicos como NS-QA (Neural-Symbolic Question Answering) [8] o NSPS (Neural-Symbolic Program Synthesis) [9]. Estos algoritmos son capaces de interpretar especificaciones de alto nivel, como descripciones de tareas o ejemplos de entrada/salida, y, a partir de ellas, generar automáticamente soluciones estructuradas en forma de programas o reglas lógicas. El módulo conexionista se utiliza para analizar y comprender los datos complejos, como texto o imágenes, y convertir esta comprensión en representaciones simbólicas que posteriormente van a ser manipuladas por el módulo simbólico para cumplir con los objetivos de la tarea especificada. Ahora no es este último el que se encarga de llamar al otro para tareas concretas, sino que los dos van trabajando a la vez para cumplir el objetivo.

Otro caso interesante lo encontramos en el sistema NS-CL (Neuro-Symbolic Concept Learner) [10], que se centra en la comprensión integrada de imágenes y lenguaje para luego realizar distintas tareas de procesamiento de lenguaje natural y visión por computador, como responder preguntas basadas en imágenes o relacionar un texto con su imagen y viceversa. En este caso, como en los ejemplos anteriores el sistema conexionista es el que se va a utilizar para la percepción visual

que se necesita para comprender las imágenes de entrada y obtener las representaciones necesarias en el procesamiento de la tarea. Por otro lado, se tiene la parte simbólica que consiste en un ejecutor de programas simbólicos que utilizan las representaciones obtenidas como base para ejecutar las reglas necesarias para la obtención de la respuesta a la pregunta inicial.

Por último, muchos de los avances que se están haciendo actualmente en el aprendizaje neuro-simbólico por refuerzo también pertenecen a este tipo, como es el caso de PEORL (Planning–Execution–Observation–ReinforcementLearning) [11]. Este modelo va a usar aprendizaje por refuerzo jerárquico, ayudado por un sistema de planificación simbólica, para la toma de decisiones en entornos dinámicos e inciertos. Este sistema va a utilizar una implementación simbólica para utilizar planes que sean capaces de guiar el aprendizaje y la ejecución de tareas. Además, este sistema de planificación también se va a ir retroalimentando de las experiencias obtenidas durante la realización de estas tareas para mejorar.

D. Tipo 4: *Neuro: Symbolic* → *Neuro*

El cuarto tipo de representaciones neurosimbólicas viene caracterizado por la "compilación" de reglas o conocimiento de forma directa en el proceso de entrenamiento o en la propia arquitectura. La idea general de estos sistemas es encontrar, o bien una codificación subsimbólica para elementos simbólicos, o una estructura de datos capaz de contener simbólica que permita su integración natural en la redes neuronales.




Fig. 4. Representación de los modelos de Tipo 4

A continuación, se presentan dos tendencias generales para el uso de información simbólica una vez conseguida una representación subsimbólica de los mismos:

1) *Símbolos como datos de entrenamiento*: Si atendemos a la representación de datos simbólicos, a nivel sub-simbólico, como datos de entrenamiento encontramos diferentes aproximaciones:

a) *El embedding de símbolos*: la idea general subyacente es generar representaciones vectoriales de conocimiento simbólico, a través de auto-encoders o similares.

Como ejemplo general de la mayoría de este tipo de propuestas, en [12] se plantea el uso de un tipo especial de autoencoders (SD-VAE), inspirado en la teoría de los compiladores, que permite restringir el espacio de resultados para que la salida no solo sea sintácticamente válida sino también semánticamente razonable.

Otro ejemplo de este tipo de aproximación, que abarca más que solo la codificación de los datos simbólicos, sería

la propuesta de [13]. Los autores plantean una nueva arquitectura de redes neuronales con el objetivo de obtener representaciones semánticas continuas de expresiones algebraicas y lógicas (SEM VECS). Las redes de equivalencia neuronal (EQ-NET) se entrenan para representar internamente de forma parecida aquellas expresiones semánticamente similares aunque sintácticamente sean muy diferentes, de tal forma que se pudiera llegar a plantear la resolución de problemas simbólicos como procesos de búsqueda a través de una métrica de distancia en un espacio continuo.

Para poder entrenar la arquitectura propuesta, obtienen los SEM VECS a partir de un conjunto de datos que posee pares de expresiones relacionadas por su equivalencia semántica y emplean un método (subexpression autoencoding) que fuerza, a través de un autoencoder con restricciones, que la codificación de las subexpresiones de un predicado sea reversible y predecible a partir de sus vecinos sintácticos. Se podría decir que el embedding de los datos codifica las relaciones entre expresiones y la red es la que pondera y representa internamente el aspecto más relevante, buscando en este caso que la semántica sea la que predomine pero sin eliminar la sintaxis, puesto que un pequeño cambio de características sintácticas puede suponer una variación drástica de la semántica.

Un ejemplo más reciente de otro planteamiento en esta línea de investigación sería la presente en [14]. En ella, se busca representar conocimiento simbólico como reglas lógicas a través de dos lenguajes de representación diferentes: la Forma Normal Conjuntiva (CNF) y la d-DNNF. Toda lógica booleana puede ser representada en CNF pero resulta impracticable para las consultas más relevantes como la comprobación de satisfactibilidad, en contraste con la segunda forma que sufre de un crecimiento exponencial en tamaño pero permite abarcar en tiempo polinomial la mayoría de pruebas deseables como la satisfactibilidad, la enumeración, etc ... Puesto que estas formas se representan de forma natural con grafos, plantean el uso de redes de grafos convolucionales con el uso de un tipo especial de regularización (semántica) para obtener embeddings que sean semánticamente consistentes.

b) *Árboles y gramáticas como estructuras de representación*: La segunda aproximación a la hora de codificar o representar información de carácter simbólico se centra en emplear representaciones de árboles para convertir expresiones matemáticas en datos de entrenamiento. De esta forma, se pretende que un modelo de redes neuronales profundas pueda aprender a representar y resolver expresiones matemáticas.

Esta representación aprovecha las propiedades intrínsecas de los árboles como estructuras de datos para representar operaciones tanto unitarias como binarias y símbolos terminales.

Esta forma de representar las expresiones no solo ha sido muy útil para automatizar la generación y evaluación de conjuntos de datos que contengan expresiones y su valor una vez evaluada [15], sino que también han habido propuestas en el campo del aprendizaje por refuerzo y la visión, que se apoyan en esta aproximación para plantear el uso de gramáticas formales en la ejecución de una red neuronal como forma de evaluar y recompensar, tanto positiva como




Fig. 5. Representación de expresiones matemáticas como árboles [17]

negativamente, su salida [16].

2) *Representaciones simbólicas intra-arquitectura*: Por otro lado, si nos fijamos en la integración de información simbólica, no como datos sino de forma implícita en la arquitectura del modelo, podemos destacar los siguientes enfoques:

a) *Generación de lenguajes lógicos*: El primer enfoque se centra en la creación de modelos de "question answering" capaces de generar y "ejecutar" programas simbólicos, implementados como operaciones derivables y/o redes neuronales [23]. Para la tarea específica de "visual question answering" (VQA) las aproximaciones existentes en la literatura pretenden que, a través de la generación de un conjunto de reglas en un lenguaje lógico [21], el proceso de inferencia que siga el modelo no solo se torne explícito e interpretable, por el conjunto de reglas o programa que genere, sino que también aumente su precisión, puesto que el proceso de "razonamiento" pasa a tener un carácter composicional que permite lidiar con objetos e interacciones que no haya visto previamente, cosa que la aproximación clásica del sesgo inductivo en solitario no soporta. Por ejemplo, si el usuario pregunta que si el niño toca la pelota en una imagen dada, el modelo debe ser capaz de identificar la interacción y responderla correctamente, aunque nunca la haya visto en el entrenamiento, ya que posee una descripción interna separada de lo que es un niño, una pelota y lo que entiende por tocar.

b) *Redes Neuronales de Grafos*: La segunda tendencia, que posee mucha fuerza actualmente en los áreas de visión y procesamiento del lenguaje natural, pretende emplear redes neuronales de grafos para representar entidades y relaciones.

Un ejemplo relevante de este enfoque viene dado por investigadores de DeepMind y varias universidades Norte Americanas. En este estudio [19], se desarrolla un método que propone entrenar GNNs con representaciones latentes dispersas y luego aplicar una regresión simbólica a los componentes del modelo para extraer relaciones físicas (porque el artículo está enfocado al dominio de la física) explícitas.

La regresión simbólica se realiza utilizando un algoritmo genético para combinar expresiones algebraicas y así poder generar expresiones completamente nuevas que aproximen el conocimiento deseado. Un ejemplo que se da es el de un modelo entrenado en una simulación detallada de materia oscura, que es capaz de dar una ecuación completamente nueva para aproximar la densidad de la materia oscura en un punto en base a su entorno.

Otro ejemplo es GraIL [20], un framework de redes neuronales de grafos para aprender semánticas relacionales in-

Q: *Is there a blue box in the items?* **A:** *yes*

Predicted Program:

```

exist
filter_shape[cube]
filter_color[blue]
scene
        
```

Predicted Answer:

✓ *yes*

Q: *What shape object is farthest right?* **A:** *cylinder*

Predicted Program:

```

query_shape
unique
relate[right]
unique
filter_shape[cylinder]
filter_color[blue]
scene
        
```

Predicted Answer:

✓ *cylinder*

Fig. 6. Ejemplo de ejecución de un modelo de razonamiento visual para una tarea de VQA [21]

dependientes de las entidades, enfocándose en predecir relaciones a partir de estructuras de subgrafos. Esto es gracias a un fuerte sesgo inductivo, que le permite generalizar a nodos no vistos. En el artículo original también se introducen nuevos conjuntos de datos para evaluar capacidades de razonamiento inductivo, también abordando la limitación de conjuntos existentes orientados a razonamiento transductivo.

E. Tipo 5: NeuroSYMBOLIC

Este tipo de integración se centra en incorporar conocimientos y reglas simbólicas dentro de las redes neuronales profundas (DNNs) de forma implícita en forma de restricciones en la función de pérdida empleada para su entrenamiento. De esta manera, las reglas lógicas se incrustan dentro del objetivo de aprendizaje de la red, permitiendo un entrenamiento de extremo a extremo, y con el objetivo de que la red no solo aprenda a partir de los datos, sino también de las restricciones y estructuras lógicas. Tal integración brinda una mayor flexibilidad y capacidad de generalización a las redes neuronales, buscando mejorar la interpretabilidad y robustez del modelo, especialmente en escenarios con datos limitados o ruidosos.

Existen muchas aproximaciones populares para lograr esto, como la propuesta en [25], que pretende realizar embeddings fidedignos de la información simbólica de forma iterativa y refinada en base a una función de pérdida, o incluso [26] que propone una función de pérdida específica que sea sensible a cuán cerca está la red de cumplir las restricciones

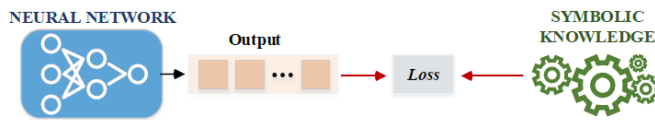


Fig. 7. Representación de los modelos de Tipo 5

de los predicados lógicos. Pero un ejemplo muy original y relativamente reciente de este enfoque son las "Logic Tensor Networks" (LTNs) [24], que convierten la lógica booleana de primer orden en lógica difusa, específicamente en operadores derivables [27] y, por tanto, compatibles con el aprendizaje basado en gradientes de las redes neuronales. Este proceso se lleva a cabo aproximando operadores lógicos no derivables (como AND, OR, NOT, IMPLICA) y cuantificadores (como EXISTE, PARA TODO) con operadores lógicos difusos que permiten representar variables con grados de verdad que varían entre 0 y 1, lo que refleja su certeza de ser falsas o verdaderas.

Otra tendencia reseñable en este enfoque es la caracterizada por el uso de jerarquías de clases (que no son más que relaciones entre entidades). En concreto, se busca diseñar clasificadores que las tengan en cuenta tanto como objetivos de clasificación, como información base de la que disponer. Para ello se pueden plantear desde arquitecturas específicas para la correcta representación del problema [28], hasta el uso de diferentes funciones objetivo, como "Hierarchical cross-entropy" [29] o nuevos métodos de embedding como "Soft labels" [29], que ayuden a mantener la coherencia entre la predicción del modelo y las restricciones asociadas.

F. Tipo 6: *Neuro[Symbolic]*

Este último enfoque se centra en una integración profunda y holística del aprendizaje basado en redes neuronales y el razonamiento simbólico. Se caracteriza, desde un punto de vista teórico, por su capacidad para fusionar de manera efectiva las fortalezas de los sistemas basados en lógica con aquellos fundamentados en el aprendizaje neural. Para ello, el conocimiento y las reglas simbólicas no solo se incorporan superficialmente o en etapas específicas del procesamiento neural; en cambio, se integran de manera más intrínseca y central en el diseño y la operación de la red neuronal. Esto apunta a mejorar la capacidad de las redes para realizar razonamientos complejos y abstractos. Al infundir estructuras y lógicas simbólicas en el corazón del aprendizaje neuronal, este enfoque busca crear modelos que no solo aprendan de los datos, sino que también incorporen y utilicen el conocimiento estructurado y las reglas de razonamiento de maneras que reflejen más fielmente los procesos cognitivos humanos.

Actualmente no se considera que exista ningún sistema o aproximación que cumpla con las características del enfoque, aunque por no matar toda esperanza podríamos afirmar que aquella propuesta que más se acerca serían las TLNs (tensor logic networks), por su capacidad de integrar estructuras que representen elementos de lógica en el centro del procesamiento de una red neuronal, sus pesos. Consideramos que, de todos los




Fig. 8. Representación de los modelos de Tipo 6

lugares en los que se pueden incorporar elementos simbólicos a una red neuronal, el de mayor dificultad e impacto es la arquitectura de la propia red junto con sus pesos, ya que comparado con la transformación de los datos de entrenamiento o las funciones de pérdidas específicas, resultan aproximaciones a nuestro parecer de mayor calibre y mucho menos frecuentes en la literatura revisada.

III. LINEAS DE INVESTIGACIÓN FUTURAS

Respecto a las líneas futuras en este campo, la principal carencia de estos sistemas integradores es la escalabilidad. Es un problema que no se menciona en esta revisión pero que resulta muy relevante, puesto que la mayoría de la literatura actual se enfoca más en obtener resultados buenos a pequeña y mediana escala sin pensar en un entorno de despliegue a gran escala. Esto por desgracia dificulta la adopción de modelos que resultan prometedores en entornos de uso diario.

Otra posible línea futura de investigación podría centrarse en investigar sistemas del tipo 6, por ejemplo, partiendo de aproximaciones bastante cercanas a este tipo, como las TLNs, e incorporando otros métodos o variantes mencionados en este trabajo, como el uso de datos de entrenamiento que representen conocimiento lógico, creación de funciones de pérdida específicas, diseño de otro tipo de arquitectura o estructura de datos que represente mejor este tipo de información, etc ...

Un último aspecto interesante al que no muchos investigadores le prestan atención es a la generalización composicional, pues resulta ser un elemento vital para este tipo de modelos, pero al que solo se le llega a prestar atención en ciertas arquitecturas concretas. Creemos que hay lugar para la innovación en el área específica que integra la capacidad de percibir bloques de información básica e indivisible, así como su uso para construir bloques de información de mayor complejidad, en las redes neuronales profundas, digamos, clásicas.

IV. CONCLUSIONES

Creemos que el área de la integración neurosimbólica resulta muy prometedora. A lo largo de esta revisión hemos presentado los enfoques y vertientes más generales de este área tan amplia y en constante evolución, usando una taxonomía ya existente para intentar incluir todas las aproximaciones relevantes. Hemos constatado que existe un número muy alto de opciones para realizar esta conexión neurosimbólica a distintos niveles de solapamiento entre las partes y utilizando

cada una de ellas para momentos distintos dentro del proceso de razonamiento del sistema.

Como resultado de este análisis, identificamos áreas promotoras para investigaciones futuras, como la mejora en la escalabilidad y la generalización compositiva de estos sistemas. A pesar de los avances observados, concluimos que aún existe un amplio margen para la innovación y el perfeccionamiento en este campo. Esta investigación subraya la necesidad de continuar explorando enfoques híbridos en la inteligencia artificial, para aprovechar al máximo las fortalezas de ambas corrientes y superar sus limitaciones individuales.

REFERENCES

- [1] Wang, W., Yang, Y., and Wu, F. (2022). Towards data-and knowledge-driven artificial intelligence: A survey on neuro-symbolic computing. arXiv preprint arXiv:2210.15889.
- [2] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," arXiv preprint arXiv:1301.3781, 2013
- [3] J. Pennington, R. Socher, and C. D. Manning, "Glove: Global vectors for word representation," in Proceedings of the Conference on Empirical Methods in Natural Language Processing, 2014, pp. 1532–1543
- [4] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell et al., "Language models are few-shot learners," in Proc. Advances Neural Inf. Process. Syst., 2020, pp. 1877–1901.
- [5] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. Van Den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot et al., "Mastering the game of go with deep neural networks and tree search," Nature, vol. 529, no. 7587, pp. 484–489, 2016.
- [6] X. Chen, C. Liang, A. W. Yu, D. Song, and D. Zhou, "Compositional generalization via neural-symbolic stack machines," in Proc. Advances Neural Inf. Process. Syst., 2020, pp. 1690–1701.
- [7] R. Dang-Nhu, "Plans: Neuro-symbolic program learning from videos," in Proc. Advances Neural Inf. Process. Syst., 2020, pp. 22 445–22 455
- [8] K. Yi, J. Wu, C. Gan, A. Torralba, P. Kohli, and J. B. Tenenbaum, "Neural-symbolic VQA: Disentangling reasoning from vision and language understanding," in Proc. Advances Neural Inf. Process. Syst., 2018, pp. 1039–1050.
- [9] E. Parisotto, A.-r. Mohamed, R. Singh, L. Li, D. Zhou, and P. Kohli, "Neuro-symbolic program synthesis," in Proc. Int. Conf. Learn. Representations, 2017
- [10] J. Mao, C. Gan, P. Kohli, J. B. Tenenbaum, and J. Wu, "The neuro-symbolic concept learner: Interpreting scenes, words, and sentences from natural supervision," in Proc. Int. Conf. Learn. Representations, 2019.
- [11] F. Yang, D. Lyu, B. Liu, and S. Gustafson, "PEORL: Integrating symbolic planning and hierarchical reinforcement learning for robust decision-making," in International Joint Conferences on Artificial Intelligence, 2018, pp. 4860–4866.
- [12] Dai, H., Tian, Y., Dai, B., Skiena, S. & Song, L. Syntax-directed variational autoencoder for structured data. *ArXiv Preprint ArXiv:1802.08786*. (2018)
- [13] Allamanis, M., Chanthirasegaran, P., Kohli, P. & Sutton, C. Learning continuous semantic representations of symbolic expressions. *International Conference On Machine Learning*. pp. 80-88 (2017)
- [14] Xie, Y., Xu, Z., Kankanhalli, M., Meel, K. & Soh, H. Embedding symbolic knowledge into deep networks. *Advances In Neural Information Processing Systems*. **32** (2019)
- [15] Lample, G. & Charton, F. Deep learning for symbolic mathematics. *ArXiv Preprint ArXiv:1912.01412*. (2019)
- [16] Li, Q., Huang, S., Hong, Y., Chen, Y., Wu, Y. & Zhu, S. Closed loop neural-symbolic learning via integrating neural perception, grammar parsing, and symbolic reasoning. *International Conference On Machine Learning*. pp. 5884-5894 (2020)
- [17] Arabshahi, F., Singh, S. & Anandkumar, A. Combining symbolic expressions and black-box function evaluations in neural programs. *ArXiv Preprint ArXiv:1801.04342*. (2018)
- [18] Lin, B., Chen, X., Chen, J. & Ren, X. Kagnet: Knowledge-aware graph networks for commonsense reasoning. *ArXiv Preprint ArXiv:1909.02151*. (2019)
- [19] Cranmer, M., Sanchez Gonzalez, A., Battaglia, P., Xu, R., Cranmer, K., Spergel, D. & Ho, S. Discovering symbolic models from deep learning with inductive biases. *Advances In Neural Information Processing Systems*. **33** pp. 17429-17442 (2020)
- [20] Teru, K., Denis, E. & Hamilton, W. Inductive Relation Prediction by Subgraph Reasoning. *Proceedings Of The 37th International Conference On Machine Learning*. **119** pp. 9448-9457 (2020,7,13), <https://proceedings.mlr.press/v119/teru20a.html>
- [21] Johnson, J., Hariharan, B., Van Der Maaten, L., Hoffman, J., Fei-Fei, L., Lawrence Zitnick, C. & Girshick, R. Inferring and executing programs for visual reasoning. *Proceedings Of The IEEE International Conference On Computer Vision*. pp. 2989-2998 (2017)
- [22] Evans, R. & Grefenstette, E. Learning explanatory rules from noisy data. *Journal Of Artificial Intelligence Research*. **61** pp. 1-64 (2018)
- [23] Zhang, L., Rosenblatt, G., Fetaya, E., Liao, R., Byrd, W., Might, M., Urtasun, R. & Zemel, R. Neural guided constraint logic programming for program synthesis. *Advances In Neural Information Processing Systems*. **31** (2018)
- [24] Badreddine, S., Garcez, A., Serafini, L. & Spranger, M. Logic tensor networks. *Artificial Intelligence*. **303** pp. 103649 (2022)
- [25] Hu, Z., Ma, X., Liu, Z., Hovy, E. & Xing, E. Harnessing deep neural networks with logic rules. *ArXiv Preprint ArXiv:1603.06318*. (2016)
- [26] Xu, J., Zhang, Z., Friedman, T., Liang, Y. & Broeck, G. A semantic loss function for deep learning with symbolic knowledge. *International Conference On Machine Learning*. pp. 5502-5511 (2018)
- [27] Krieken, E., Acar, E. & Harmelen, F. Analyzing differentiable fuzzy logic operators. *Artificial Intelligence*. **302** pp. 103602 (2022)
- [28] Giunchiglia, E. & Lukasiewicz, T. Multi-label classification neural networks with hard logical constraints. *Journal Of Artificial Intelligence Research*. **72** pp. 759-818 (2021)
- [29] Bertinetto, L., Mueller, R., Tertikas, K., Samangooei, S. & Lord, N. Making better mistakes: Leveraging class hierarchies with deep networks. *Proceedings Of The IEEE/CVF Conference On Computer Vision And Pattern Recognition*. pp. 12506-12515 (2020)